실세계 환경에서의 딥페이크 탐지 모델 성능 분석 및 개선

김주연, 김연서, QURAT UL AIN AISH,A 김병규*
숙명여자대학교 인공지능 공학부
e-mail : kim511@sookmyung.ac.kr, kys93437481@gmail.com, aisha.q@ivpl.sm.ac.kr,
bg.kim@sookmyung.ac.kr*

Performance Analysis and Improvement of Deepfake Detection Models in Real-World Environments

Joo-Yeon Kim, Yeon-Seo Kim, Byung-Gyu Kim*
*Dept of Artificial Intelligence Engineering, Sookmyung Women's University

요 약

본 연구는 손실 압축 환경에서 딥페이크 탐지 성능 저하 문제를 완화하기 위해 위상 기반 딥페이크 탐지 프레임워크를 제안한다. MoE-FFD 기반 구조에 Phase-Only Reconstruction 으로 추출한 위상 특징을 Adapter-Moe 라우팅에 통합, JPEG 압축 증강을 결합한다. FaceForensics++ 실험 결과, 제안 방법은 c40 환경에서 AUC 76.64%를 달성하여 Baseline 대비 3.71%p 향상을 보였으며, JPEG Q=60 조건에서는 97.3%의 AUC 를 기록하여 Baseline 보다 4.75%p 높은 성능을 보여 주었다.

1. 서론

최근 딥러닝 기반 생성 기술의 발전으로 실제 영상과 구별하기 어려운 고품질의 딥페이크 콘텐츠가 생성되고 있다. 이러한 기술은 영상 제작 및 콘텐츠 생성 등 다양한 분야에서 활용될 수 있으나, 허위 정보의 확산, 신원 도용, 디지털 미디어의 신뢰성 훼손과 같은 문제를 야기할 수 있다.

기존 딥페이크 탐지 모델은 얼굴의 경계, 텍스처, 픽셀 간 불일치 등 공간적 특징(Spatial Features)을 학습하여 위조 여부를 판별한다. 그러나 실제 소셜 네트워크 서비스(SNS)나 영상 공유 플랫폼에서는 저장 및 전송 효율을 높이기 위해 손실 압축이 적용되며, 반복적인 압축 과정에서 고주파 성분과 같은 미세한 텍스처 정보가 손상될 수 있다. 이러한 정보 손실은 위조 영상의 특징을 약화시키고, 공간적 단서에 크게 의존하는 탐지 모델의 성능 저하로 이어질 수 있다.

최근 제안된 MoE-FFD[1]는 Vision Transformer(ViT) 기반으로 LoRA-MoE 와 Adapter-MoE 를 결합하여 얼굴 위조를 탐지한다. 그러나 공간적 토큰 표현에 의존한 전문가 라우팅 구조로 인해 압축 환경에서 성능이 저하된다. 실제로 FF++[4]의 c23 에서 AUC 는 98.93%를 기록하였으나, c40 에서는 72.93%로 감소하였다.

본 연구는 2D FFT 위상 정보 기반의 Phase-Guided Adapter-MoE Routing 딥페이크 탐지 프레임워크를 제안한다. 또한 구조적 개선과 함께 학습 단계에서 JPEG 압축 증강을 적용하여 다양한 압축 열화 조건에 대한 적응력을 높이고자 하였다. 주요 기여는 다음과 같다.

(1) Phase-Guided Adapter-MoE Routing: 2D FFT 기반 위상 특징과 공간적 특징을 결합한 1536 차원 게이팅 입력을 구성하여 Adapter-MoE 의 전문가 선택을 보조한다.

(2) 구조적 특징과 데이터 증강의 결합: Phase-Only Reconstruction 기반 특징 추출과 JPEG Compression Augmentation 을 활용한다.

(3) 압축 강건성 실험 검증: FF++ c23 에서 c40 으로의 교차 압축 평가 및 JPEG 품질별 실험을 통해 제안 방법의 효과를 분석한다.

2. 관련연구

2.1. Deepfake Detection under Compression

딥페이크 탐지 연구는 얼굴 조작 과정에서 발생하는 시각적 불일치와 인공적인 특징을 분석하는 방향으로 발전해 왔다. CNN 및 Transformer 기반 탐지 모델은 얼굴 경계의 부자연스러움, 텍스처 왜곡, 픽셀 수준의 불일치와 같은 공간적 특징을 학습하여 실제 영상과 위조 영상을 구별한다. 이러한 접근은 고품질 데이터에서 효과적인 판별 성능을 보일 수 있지만, 입력 영상의 품질이나 압축 수준이 변화할 경우 탐지에 활용되는 미세한 특징이 손상될 수 있다는 한계가 있다. FaceForensics++[4]는 c23 과 c40 등 서로 다른 압축 조건을 제공하여 탐지 모델의 압축 강건성을 평가하는 대표적인 벤치마크 데이터셋이다.

2.2. Frequency and Phase-Based Forgery Detection

공간 영역의 특징에만 의존하는 탐지 방식의 한계를 보완하기 위해 주파수 영역 정보를 활용하는 연구가 진행되어 왔다. 영상의 주파수 표현은 일반적으로 진폭(Magnitude)과 위상(Phase) 성분으로 구분된다.

Oppenheim 과 Lim[2]은 신호 재구성에서 위상 정보의 중요성을 분석하였으며, 위상이 신호의 구조적 특징을 결정하는 데 핵심적인 역할을 함을 보였다. 이러한 위상 정보의 특성은 얼굴 위조 탐지에도 활용되어 왔다. Liu et al.[3]이 제안한 SPSL 은 위상 기반 표현을 활용하여 위조 과정에서 발생하는 주파수 특성을 포착한다. 본 연구는 기존의 위상 기반 탐지 방법과 달리 위상 정보를 최종 분류 특징으로 직접 결합하는 대신, MoE 의 전문가 선택을 위한 게이팅 입력으로 활용한다.

2.3. Mixture-of-Experts for Face Forgery Detection

Mixture-of-Experts(MoE)[5]는 다수의 전문가 네트워크와 게이팅 네트워크로 구성되며, 입력 특징에 따라 일부 전문가를 선택적으로 활성화하는 구조이다. 조건부 계산(Conditional Computation) 방식으로 모든 전문가를 동시에 사용하지 않으면서도 다양한 특징을 학습하고 활용할 수 있도록 한다.

MoE-FFD[1]는 이러한 MoE 구조를 얼굴 위조 탐지에 적용한 방법으로, ViT-B/16 백본에 LoRA-MoE 와 Adapter-MoE 를 결합한다. LoRA-MoE 는 Self-Attention 영역에서, Adapter-MoE 는 Feed Forward Network(FFN) 영역에서 전문가 모듈을 활용한다. 그러나 공간적 토큰 표현 기반의 라우팅은 손실 압축에 의해 입력 특징이 변화하면 게이팅 결정에도 영향을 미칠 가능성이 있다. 본 연구에서는 이를 보완하기 위해 Phase-Only Reconstruction 으로 얻은 위상 특징을 Adapter-MoE 의 게이팅 과정에 추가한다.

3. 제안 방법

3.1. Overall Framework

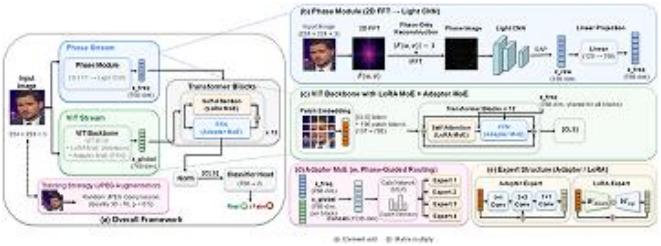


그림 1. 제안 프레임워크의 전체 구조

본 연구에서는 손실 압축 환경에서 발생하는 딥페이크 탐지 성능 저하를 완화하기 위해, 위상 기반 구조적 특징을 활용한 Phase-Guided Mixture-of-Experts(MoE) Routing 과 JPEG Compression Augmentation 을 결합한 프레임워크를 제안한다. 제안 프레임워크는 Phase Stream 과 ViT Stream 두 가지의 병렬 경로로 구성된다. Phase Stream 은 2D FFT 와 Phase-Only Reconstruction 을 통해 위상 기반 구조적 특징을 추출하고, 경량 CNN 과 선형 투영을 거쳐 768 차원의 위상 특징 벡터 z_freq 를 생성한다. ViT Stream 은 기존 MoE-FFD 구조를 활용하여 공간적 토큰 표현을 학습한다. 두 경로의 특징은 각 Transformer Block 의 Adapter-MoE 게이팅 과정에서 결합된다. 또한 학습 단계에서는 JPEG Compression Augmentation 을 적용하여 다양한 압축 열화 조건에 대한 적응력을 높인다. 이러한 구조적 특징 보완과 데이터 증강의 결합을 통해 고도 압축 환경에서의 탐지 강건성을 향상시키고자 한다.

3.2. Phase-Only Reconstruction

일반적으로 이미지의 주파수 표현은 진폭(Magnitude)과 위상(Phase) 성분으로 구분된다. 진폭은 각 주파수 성분의 크기를 나타내는 반면, 위상은 주파수 성분 간의 상대적 관계를 통해 이미지의 경계와 공간적 구조를 표현하는 데 중요한 역할을 한다[2]. 본 연구에서는 이러한 위상 정보의 특성을 활용하여 공간적 특징을 보완할 수 있는 구조적 표현을 추출한다.

입력 이미지 x 에 대해 2D FFT 를 적용하여 주파수 표현 F(x)를 얻는다. 위상 각도 $\phi(x) = \angle F(x)$를 추출하고, 진폭을 단위 크기(magnitude=1)로 정규화하는 Phase-Only Reconstruction 을 수행한다.

$$x_{\text{phase}} = \text{Re}\left[\mathcal{F}^{-1}\left(\exp(j \cdot \varphi(x))\right)\right]$$

재구성된 위상 이미지는 채널 방향 평균과 표준편차로 정규화된 후, 경량 CNN 과 GAP 을 통해 128 차원 벡터로 압축된다. 이후 선형 투영을 거쳐 768 차원의 위상 특징 벡터 z_freq 로 변환되며, 이 벡터는 모든 Transformer Block 의 Adapter-MoE 게이팅 과정에 공유된다.

3.3. Phase-Guided Adapter-MoE Routing

기존 MoE-FFD[1]는 ViT-B/16 백본에 LoRA-MoE 와 Adapter-MoE 를 결합하여 입력 특징에 따라 적절한 전문가를 선택하는 구조를 사용한다. 그러나 공간적 토큰 표현 기반의 라우팅 수행 중 압축에 의해 공간적 특징이 손상되는 경우 게이팅 결정 역시 영향을 받을 수 있다. 이를 보완하기 위해 본 연구에서는 Phase-Guided Adapter-MoE Routing 을 제안한다. 이 방법은 공간적 특징과 위상 기반 구조적 특징을 결합하여 Adapter-MoE 의 게이팅 입력을 구성한다.

첫 번째 Transformer Block 에서 토큰 표현의 평균을 계산하여 768 차원 전역 공간 특징 x_global 을 생성하고, Phase Stream 의 z_freq 과 결합하여 1536 차원의 게이팅 입력을 구성한다.

$$g^{(l)} = \text{Concat}(x_{\text{global}}^{(l)},\ z_{\text{freq}}) \in \mathbb{R}^{B \times 1536}$$

결합된 특징은 Adapter-MoE 의 게이팅 네트워크에 입력되어 Noisy Top-k Routing[5]을 통해 전문가를 선택적으로 활성화한다. 선택된 전문가의 출력은 게이팅 가중치에 따라 결합되어 Adapter-MoE 의 출력 표현을 구성한다. 본 연구에서는 기존 LoRA-MoE 라우팅은 유지하고 Adapter-MoE 게이팅에만 위상 정보를 추가한다. 이를 통해 기존 MoE-FFD 구조를

유지하면서 압축에 의해 열화된 공간적 특징을 보완하는 라우팅 메커니즘을 구현한다.

3.4. JPEG Compression Augmentation

학습 단계에서 JPEG Compression Augmentation 을 적용한다. 확률 p=0.5 로 JPEG 압축을 적용하며, 품질 계수 q 는 30~70 범위에서 무작위로 선택한다. 평가 단계에서는 별도의 압축 증강을 적용하지 않는다.

4. 실험

4.1. 실험 설정

FF++[4]의 c23 데이터를 학습에 사용하였으며, 공식 데이터 분할을 따랐다. 사전학습된 ViT-B/16(ImageNet-21k) 백본을 기반으로, Optimizer 는 Adam(lr=3e-5, weight_decay=1e-5), 학습률 스케줄러로는 StepLR(step size=5, γ=0.5)을 적용하였다. 배치 크기 32, 총 20 에폭 동안 NVIDIA RTX 3090 GPU 에서 학습을 진행하였다. 학습 손실은 CrossEntropy Loss 와 MoE Load-Balancing Loss 의 합으로 구성된다. 평가 지표로는 비디오 수준의 ACC 와 AUC 를 사용하였다.

4.2. 교차 압축 일반화 성능

표 1. FaceForensics++ 교차 압축 일반화 성능 비교.

Method	c23		c40	
	ACC	AUC	ACC	AUC
Baseline (MoE-FFD)	95.86	98.93	62.02	72.93
+JPEG Augmentation	94.00	97.83	69.48	76.21
+Phase+Aug (Ours)	93.86	98.13	**66.33**	**76.64**

표 1 은 c23 에서 학습한 후 c23 및 c40 테스트 환경에서의 성능을 비교한 결과이다. c40 환경에서 Baseline 이 AUC 72.93%로 약 26%p 의 성능 하락을 보인 반면, 제안 방법(Phase+Aug)은 76.64%를 달성하여 3.71%p 향상되었다. JPEG 증강 단독(76.21%)과 비교하면 0.43%p 추가 향상을 보였다.

4.3. 압축 수준별 강건성 평가

표 2. JPEG 압축 수준별 강건성 평가.

Method	AUC (%)		
	Q=100	Q=80	Q=60
Baseline (MoE-FFD)	98.9	96.4	92.5
+JPEG Augmentation	98.3	97.0	95.8
+Phase+Aug (Ours)	**98.7**	**97.9**	**97.3**
Phase w/o Recon (Ablation)	86.4	83.5	81.3

표 2 는 c23 검증 데이터에 JPEG 품질 계수 Q=100, 80, 60 을 후처리로 적용한 평가 결과이다. Phase-Only Reconstruction 없이 위상 특징을 적용한 어블레이션 모델(Phase w/o Recon)을 포함한다.

Q=60 고압축 조건에서 제안 방법은 AUC 97.3%를 달성하여 Baseline(92.5%) 대비 4.75%p, JPEG 증강 단독(95.8%) 대비 1.5%p 높은 성능을 보였다. 어블레이션 모델은 모든 압축 수준에서 현저히 낮은 AUC 를 기록하여(Q=60: 81.3%), Phase-Only Reconstruction 이 압축 강건성의 핵심 요소임을 입증한다.

5. 결론

본 논문에서는 손실 압축 환경에서 취약해지는 딥페이크 탐지 모델을 보완할 수 있는 접근 방안을 제시하였다. 2D FFT 기반 Phase-Only Reconstruction 으로 진폭 정보를 제거한 위상 이미지를 생성하고, 이를 Adapter-MoE 의 게이팅 입력에 통합함으로써 압축으로 인해 공간적 특징이 열화되더라도 위상 기반 구조 정보가 전문가 선택을 보조할 수 있도록 하였다.

다만 제안 방법은 FF++[4] 데이터셋 내 압축 조건 변화에 대한 강건성 평가를 중심으로 수행되었으므로, SNS, 동영상 플랫폼 등 실제 미디어 유통 환경에서의 딥페이크 탐지에 활용될 수 있다. 실환경에서는 동일 영상이 반복 압축되거나 다양한 품질로 변환되는 경우가 많아 압축 수준 변화에 강건한 탐지 모델이 요구된다. 향후 연구에서는 반복 압축, 비디오 인코딩 등 더 다양한 열화 조건과 데이터셋으로 범위를 확장하고자 한다.

참고문헌

[1] C. Kong et al., "MoE-FFD: Mixture of Experts for Generalized and Parameter-Efficient Face Forgery Detection," IEEE Trans. Dependable Secure Comput., vol. 23, no. 1, pp. 82- 96, 2026.

[2] A. V. Oppenheim and J. S. Lim, "The Importance of Phase in Signals," Proc. IEEE, vol. 69, no. 5, pp. 529- 541, 1981.

[3] H. Liu et al., "Spatial-Phase Shallow Learning: Rethinking Face Forgery Detection in Frequency Domain," in Proc. IEEE/CVF CVPR, 2021, pp. 772- 781.

[4] A. Rössler et al., "FaceForensics++: Learning to Detect Manipulated Facial Images," in Proc. IEEE/CVF ICCV, 2019, pp. 1- 11.

[5] N. Shazeer et al., "Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer," in Proc. ICLR, 2017.